

(الف)

degree

$$k_1 = 2 \quad k_2 = 4 \quad k_3 = 2 \quad k_4 = 1 \quad k_5 = 2 \quad k_6 = 1 \quad k_7 = 1$$

closeness centrality

$$C_u = \frac{N-1}{\sum_{u \neq v} \text{Shortest path length between } u \text{ and } v}$$

	1	2	3	4	5	6	7
1	0	1	1	2	2	3	
2	1	0	1	1	1	2	
3	1	1	0	2	2	3	
4	2	1	2	0	2	3	
5	2	1	2	2	0	1	
6	3	2	3	3	1	0	
7							0

$$C_1 = \frac{7-1}{9} = 0.6666 \quad (1-2, 1-3, 1-4, 1-5, 1-6, 1-7)$$

$$C_2 = \frac{6}{9} = 0.6666 \quad (2-1, 2-3, 2-4, 2-5, 2-6, 2-7)$$

$$C_3 = \frac{6}{9} = 0.6666 \quad (3-1, 3-2, 3-4, 3-5, 3-6, 3-7)$$

$$C_4 = \frac{6}{10} = 0.6 \quad (4-2, 4-3, 4-5, 4-6, 4-7)$$

$$C_5 = \frac{6}{10} = 0.6 \quad (5-2, 5-3, 5-4, 5-6, 5-7)$$

$$C_6 = \frac{6}{12} = 0.5 \quad (6-2, 6-3, 6-4, 6-5, 6-7)$$

betweenness

تعداد بیشترین مسیرهای کوتاه بین دو گره
 $C_v =$ تعداد بیشترین مسیرهای کوتاه بین دو گره
 $S \neq v \neq t$

$$C_1 = C_4 = C_5 = C_6 = 0$$

All shortest path

1-2, 1-3, 1-2-4, 1-2-5, 1-2-5-6, 2-3, 2-4, 2-5, 2-5-6, 3-2-4, 3-2-5, 3-2-5-6, 4-2-5, 4-2-5-6, 5-6

$$C_2 = \frac{1}{1} + \frac{1}{1} + \frac{1}{1} + \frac{1}{1} + \frac{1}{1} + \frac{1}{1} + \frac{1}{1} + \frac{1}{1} = 8$$

1-2-4, 1-2-5, 1-2-5-6, 2-3, 2-4, 2-5, 2-5-6, 3-2-4, 3-2-5, 3-2-5-6, 4-2-5, 4-2-5-6, 5-6

$$C_5 = C_6 = \frac{1}{1} + \frac{1}{1} + \frac{1}{1} + \frac{1}{1} = 4$$

1-2-5-6, 2-3, 2-4, 2-5, 2-5-6, 3-2-4, 3-2-5, 3-2-5-6, 4-2-5, 4-2-5-6, 5-6

کاربرد در رای بیشترین درجه با ارزش 4 است و کاربرد آن 4 و 4 دارای کمترین با مقدار 1
 کاربرد 2، دارای بیشترین درجه 2 است و کاربرد 2 دارای کمترین مقدار 2
 کاربرد 1، دارای بیشترین درجه 1 است و کاربرد 1 دارای کمترین مقدار 1
 درجه یک کاربرد می تواند از یک منبع محبوب به یک سطح فعالیت 3 آن کاربرد در شبکه باشد از closeness
 می توان برای اندازه گیری اینکه کاربرد چه سرعتی می تواند اطلاعات یا نفوذ را از طریق شبکه
 منتشر کند و از betweenness برای شناسایی کاربرانی که می توانند واسطه های مهم بین بخش های
 مختلف شبکه عمل می کنند استفاده کرد.

با مقایسه کاربرد بر اساس این معیارهای مرکزیت می توانیم به زنجیران و حاکمیت داران اسپی
 در شبکه و همچنین کاربران
 نیاز دارند به درک شبکه های اجتماعی

به عنوان مثال در شبکه اجتماعی میهن کار بر اساس هر سه معیار مرکزیت نا خیر از این
 کار بر است نشان می دهد این کار بر اعتنا کافی با زدن لایکی و نا خیر زدن در شبکه است
 کار بران ۴ در کمترین درجه و ۵ درجه ها، دارند که نشان می دهد در میان است شامل و نفوذ
 معنوی در شبکه دارند با این کار بر ۱ و ۲ و ۳ کمترین Betweenness دارند نشان می دهد
 آنها واسطه های مهمی بین بخش های مختلف شبکه نیستند به طور کلی این معیارهای مرکزیت
 می تواند بیش های ارزشمند را برای مهندسی وبی در میان های با دگری ما بین ارائه
 دهند که رفتار شبکه اجتماعی یا شامل را بر این پیش بینی می کنند

(۵)

تعداد یاه های در بین همسایه های

$$e_v = \frac{r_v - 1}{\binom{k_v}{2}}$$


$$e_1 = \frac{1}{\binom{2}{2}} = 1$$

$$e_2 = \frac{1}{\binom{4}{2}} = \frac{1}{6} = 0.16666$$

$$e_3 = \frac{1}{\binom{2}{2}} = 1$$


$$e_4 = e_5 = e_6 = 0$$

$k=3$







g_3





g_8






g_9



$$f_0 = (1, 0, 0, 0)^T$$






$$[1, 1, 0, 0]$$



$$[1, 1, 1, 0]$$

g_{10}




$$[1, 1, 1, 0]$$

g_{11}



$$[1, 0, 0, 0]$$

g_{12}



$$[1, 0, 1, 0]$$

رأس ۴



a b c d
[۱ ۰ ۵ ۰ ۵]

(ب) ضریب فروشه بندی معیاری است که نشان می دهد یک کراف مقدار معلوم است کمیت می کنند رأس ها مقدار متقابل به شکل مثلث دارند در این جا رأس ۱ و ۲ دارای ضریب فروشه بندی ۱ هستند به این معنی که همه همسایگان آنها به یک دیگر متصل هستند رأس ۲ دارای ضریب فروشه بندی ۲/۳ است که نشان می دهد نسبت به رأس های ۱ و ۳ مثلث های کمتری دارد. رأس های ۳ و ۴ دارای ضریب فروشه بندی ۰ هستند به این معنی که جزو هیچ مثلثی نیستند

گراف با اندازه ۳ تعداد زیرگراف های ضریب هم شکلی متصل به اندازه ۳ در گراف است در اینجا رأس ۲ دارای بالاترین تعداد گراف است ۱ است به این معنی که در بیشترین زیرگراف های ۳ در گراف است رأس ۳ و ۴ به ترتیب دارای تعداد گراف است های ۳ و ۴ هستند که نشان می دهد در تعداد کمتری دیگر هستند رأس های ضریبی با اندازه ۳ نسبت به رأس ۲. رأس های ۳ و ۴ دارای تعداد گراف است ۱ هستند به این معنی که آنها فقط در یک نوع زیرگراف با اندازه ۳ درگیر هستند

در نظر مقایسه می توان دید که رأس ۲ تعداد گراف است های بالاتر و ضریب فروشه بندی کمتر است نسبت به رأس های ۱ و ۳. این نشان می دهد که رأس ۲ در زیرگراف های بیشتری با اندازه ۳ درگیر است اما مثلث های کمتری نسبت به رأس ۱ و ۳ دارد رأس های ۳ و ۴ کمترین مقدار برابر برای هر دو اندازه گیری دارد که نشان می دهد در مقایسه با رأس های دیگر در گراف کمتر به هم متصل هستند و کمتر درگیر زیرگراف های اندازه ۳ هستند

(ح) کاربرد $Betweenness$ بیشتر در افتقار بیشترین تأثیر را بر تعاملات شبکه دارد این هم این دلیل است که $Betweenness$ تعداد بارهایی که یک کاربر به عنوان یک در مسیر کوتاه ترین مسیر بین کاربر دیگر در شبکه عمل می کند را اندازه می گیرد بنابراین یک کاربر $Betweenness$ با توانایی بیشتری برای کنترل جریان اطلاعات و تأثیرگذاری بر تعاملات این دیگر کاربران در شبکه دارد البته این فقط یک معیار است و ممکن است عوامل دیگری وجود داشته باشد که در شناسایی بهترین استفاده از شبکه های اجتماعی برای تبلیغات هدفمند مؤثر باشد به عنوان مثال یک کاربر با نفوذ مرکزی در یک شبکه ممکن است تعداد زیادی از ارتباطات مستقیم داشته باشد و ممکن است بتواند به مخاطبان بیشتری دسترسی پیدا کند در حالی که یک کاربر با نفوذ $classe$ با یک در شبکه معهود تأثیر زیادی را ندارد برای شناسایی بهترین استفاده از شبکه های اجتماعی برای تبلیغات هدفمند تحلیل مباحثی از دریا رفتار شبکه و رفتار کاربر را هم لازم است.

distant Based feature

(د)

$$S_{12} = S_{13} = S_{14} = S_{15} = S_{16} = 1$$

$$S_{14} = S_{15} = S_{24} = S_{34} = S_{35} = S_{45} = 2$$

$$S_{14} = S_{34} = S_{45} = 3$$

local neighborhood:

common neighbors & jaccard's coefficient, Adamic-Adar

$$|N(1) \cap N(2)| = |\{3\}| = 1 \quad |N(1) \cup N(2)| = \{1, 2, 3, 4, 5, 6\} = 6$$

$$\frac{1}{6} = 0.1667 \quad \text{JC} = \frac{cn}{|N(1) \cup N(2)|} \quad aa = \frac{1}{\log k_p} = \frac{1}{\log 2} = 1.4427$$

$$|N(1) \cap N(3)| = |\{2\}| = 1 \quad |N(1) \cup N(3)| = \{1, 2, 3, 4, 5\} = 5 \quad \text{JC} = \frac{1}{5} = 0.2$$

$$aa = \frac{1}{\log k_p} = \frac{1}{\log 3} = 0.721347$$

$$|N(2) \cap N(3)| = |\{4\}| = 1 \quad |N(2) \cup N(3)| = \{2, 3, 4, 5, 6\} = 5$$

$$\text{JC} = \frac{1}{5} = 0.2 \quad aa = \frac{1}{\log k_p} = \frac{1}{\log 2} = 1.4427$$

$$|N(2) \cap N(4)| = 0 \quad |N(2) \cup N(4)| = \{2, 3, 4, 5, 6\} = 5$$

$$\text{JC} = \frac{0}{5} = 0 \quad aa = \frac{1}{\log 0} = 0$$

$$|N(2) \cap N(5)| = 0 \quad |N(2) \cup N(5)| = \{2, 5, 3, 4\} = 4$$

$$\delta C = \frac{0}{4} = 0 \quad aa = \frac{1}{\log 5} = 0$$

$$|N(5) \cap N(4)| = 0 \quad |N(5) \cup N(4)| = \{5, 2, 3\} = 3$$

$$\delta C = \frac{0}{3} = 0 \quad aa = \frac{1}{\log 5} = 0$$

معمولاً یگرهای مشترک common neighbors: یاه‌های بین ۳ و ۵ و ۲ و ۳ بیشترین تعداد همسایه‌های مشترک را دارند. این نشان می‌دهد نسبت به سایر یاه‌ها بیشتر می‌کنند.

Adamic-Adar: یاه‌های بین رأس‌های ۳ و ۵ دارای بالاترین ضریب جابجایی هستند. نشان می‌دهد بیشترین همسایگی‌ها را دارد. بنابراین اهمیت بیشتری دارند.


Adamic-Adar: یاه‌های ۳ و ۵ و ۲ و ۳ دارای بالاترین ضریب جابجایی هستند. نشان می‌دهد اهمیت بیشتری آن‌ها نسبت به سایر یاه‌ها است.

distant: یاه‌های بین ۲ و ۳ و ۴ و ۵ و ۲ و ۵ دارای کمترین فاصله هستند. نشان می‌دهد دلیل اتصال بیشتر به یاه‌های دیگر در شبکه اهمیت بیشتری دارند.

مثال: الف) در الگوریتم $node2vec$ به ازای تمام رئوس آن شبکه یک تعداد قدم زدن تصادفی در نظر می‌گیریم

طول قدم زدن تصادفی را l می‌گیریم و به ازای آن رئوس ها تمام رئوس های که در همسایگی آن رئوس هستند به ازای قدم زدن تصادفی می‌گذاریم $1/8(1)$ در این روال به تک تک رئوس ها به نوبتی حالت وزن می‌دهیم و براساس وزن ها رئوس های همسایگی را انتخاب می‌کنیم و از آنجا $randomwalk$ می‌سازیم این الگوریتم انجام پیدا می‌کند تصادفی با یک الگوریتم بر روی نمودار است با یک قدم زدن های تصادفی توسط با رسترهای l گزین می‌شوند که درجه BFS و DFS را گزین می‌کنند در $node2vec$ سعی برای این است که قدم زدن تصادفی طوری انتخاب شود که هم همسایگی های محلی (BFS) و هم همسایگی های سراسری DFS تعادل بینشان برقرار کند و هر دو را به نوبتی یادگرفته باشد

وقتی می‌خواهیم یک رئوس انتخاب کنیم اینکه در آنجا چه رئوس هایی انتخاب کردیم مهم اند و ما این را می‌دانیم در $Deepwalk$ تمام این کارها تصادفی بود و وقتی می‌خواهیم (w) را انتخاب کنیم اصلاً نمی‌دانستیم که قبلاً در رئوس u بوده اطاعتی در موردش ذخیره نشده بود و ما آن را هم اصلاً اعمال نمی‌کردیم اما در $node2vec$ که $node2vec$ که یک از اینهاست در واقع اطاعات قبلی در انتخاب های بعدی اعمال می‌شود در $node2vec$ هر دو روش BFS و DFS در انتخاب مسیری از گره ها اعمال می‌شود اما در $Deepwalk$ با صرف فقط نزدیکترین محلی رئوس ها BFS در یک گراف انجام می‌دهد



$$p = 100 \quad q = 1$$

$$\frac{1}{p} = \frac{1}{100} = 0.01$$

$$\frac{1}{q} = \frac{1}{1} = 1$$

مثلاً از رئوس D شروع می‌کنیم و می‌خواهیم یک قدم زدن تصادفی به طول ۲ طی کنیم

$$n = \frac{1}{p} + \frac{1}{q} + 1 = 1.01 + 1 = 2.01$$

$$\frac{1}{p} \times \frac{1}{n} = 0.0099 \quad \text{نشان دهنده احتمال برگشتن به A} \quad 1 \times \frac{1}{n} = 0.4975 \quad \text{BFS از A به B}$$

$$\frac{1}{q} \times \frac{1}{n} = 0.4975 \quad \text{DFS از A به B}$$

چ. به تمام بعدی رفتن

م و چ را کار بر انتخاب می کند


م احتمال بازگشت

$\frac{1}{p}$ و $\frac{1}{q}$ را احتمال های نشان شده بیشتر برای همین m را حساب کردیم و این احتمالات را در $\frac{1}{n}$ ضرب کردیم

اگر کم باشد $\frac{1}{p}$ بزرگ است اما اهمیت بیشتری به BFS می دهیم طول ۷ و خود ۷ هم سایر محلی می شود چ هم BFS را مشخص می کند چون بازی کردیم به تمام اول

اگر با مترم را بزرگ در نظر بگیریم بزرگتر از $\max(q)$ بنابراین چون $\frac{1}{p}$ در نظر می گیریم مقدارش کوچک می شود و احتمال اینکه برگردیم به آن راس ها کمتر قبلاً در آن بهیم احتمالشان کمتر می شود اگر کم کوچک باشد از $\min(q)$ کمتر باشد در این صورت چون $\frac{1}{p}$ به عنوان احتمال در نظر می گیریم شغل بزرگ در به نقاط قبلی احتمال اینکه در حسابگرهای محلی یا BFS بماند بیشتر می شود. اگر با مترم چ را فرض کنیم بزرگتر از ۱ است بنابراین احتمال $\frac{1}{p}$ کوچک است بنابراین احتمال اینکه در شغل کمتر می شود اگر $q < 1$ باشد احتمال اینکه DFS انجام شود و ما دور شویم زیاد می شود اگر $p = 2$ و $q = 0.5$ باشد روی تصادفی به سمت راس های درست می نهد که نزدیک تر هستند و اگر $p = 2$ و $q = 0.5$ باشد روی تصادفی به سمت راس های درست می نهد که دورتر هستند

چ. یک قدم زدن تصادفی به طول ۲ از راس ۱ با یا مترها $p = 2$ و $q = 1$ شروع می کنیم و به صورت تصادفی به راس ۲ یا شروع بعد از آن برای رفتن به راس بعدی چون به راس سه می ریم رفت یا به ۱ بازگشت برای بازگشت به راس ۱ احتمال $\frac{1}{p}$ در نظر گرفته



برای رفتن به راس ۳ هر دو هم احتمال $\frac{1}{p}$ و رفتن به راس ۳ احتمال $\frac{1}{p}$ در نظر می گیریم

برای نرمالیز کردن مقادیر احتمالات داریم:

$$n = \frac{1}{p} + \frac{1}{q} + \frac{1}{q} + 1 = 0.5 + 1 + 1 + 1 = 3.5$$

$$\frac{1}{p} = \frac{1}{2} = 0.5$$

$$\frac{1}{q} = \frac{1}{1} = 1$$

$$\frac{1}{p} \times \frac{1}{n} = 0.1428$$

$$\frac{1}{q} \times \frac{1}{n} = 0.2857$$

$$1 \times \frac{1}{n} = 0.2857$$

نیا بر این 1×10^6 تا 10^7 + 10^8 + 10^9 بر اساس این اعداد ما رفتن بر این

بجای را انتخاب می کنیم چون مقدار $\frac{1}{10}$ و $\frac{1}{100}$ بیشتر از $\frac{1}{10}$ هستند پس ما به $\frac{1}{10}$ بر می گردیم و می توانیم با 10^6 یا 10^7 یا 10^8 روی مثال ما رفتن به هر انتخاب می گردیم بنابراین راه رفتن تصادفی نمونه برداری شده به طول 10^6 که از $\frac{1}{10}$ شروع می شود 10^6 و 10^8 است

ج) $node2vec$: نقاط قوت: امکان جست و جوی منعطف تر گراف را با تنظیم پارامترهای p و q فراهم می کند که تعادل بین BFS و DFS را کنترل می کند. و اینکه نسبت به فقط بر اساس اعداد با یکسان انتخاب شوند برای حفظ ساختار گراف محلی و جهانی طراحی شده و برای کارهای پایین دستی که به هر دو نوع اطلاعاتی ممکن هستند مفید است این الگوریتم را می توان با استفاده از تکنیک های موازی سازی روی گراف های بزرگ آموزش داد.

پسیدگی زمانی به طور کلی است پس پیدگی محاسباتی کم است به دلیل اینکه ما طول قدم زدن تصادفی را fix کرده و تعداد آن ها را یک چیز ثابت نگه داریم و ما فقط با $\frac{1}{10}$ یا $\frac{1}{100}$ یا $\frac{1}{1000}$ روی قدم زدن تصادفی هستند این مراحل به نوعی به هم وابسته نیستند روشی سریع است.

عیب: به تنظیم چندین پارامتر مانند p و q و طول قدم زدن تصادفی و تعداد قدم ها نیاز دارد که می تواند زمان بسیار باشد.

ممکن است در گراف هایی با توزیع درجه بسیار منفی یا ساختارهای خاص پس پیدگی به نوعی مشکل آلوده.

$Deepwalk$: نقاط قوت: یک الگوریتم ساده تر است که پیاده سازی آن آسان است و می تواند برای جفت گسترده ای از گراف ها مورد استفاده قرار گیرد. می توان با استفاده از $Deepwalk$ تصادفی توان $Deepwalk$ را آموزش داد و می تواند گراف های بزرگ با تعداد زیاد رأس و لبه را مدیریت کند.

عیب: فقط ساختار گراف محلی را حفظ می کند و ممکن است به اندازه $node2vec$ اطلاعات سراسری را ضبط نکند.

باز به جست و جوی منعطف تر را در گراف می دهد.





ممکن است در گراف های با ساختارهای پیچیده اجتماعی یا ویژگی های خاص با ایجاد با
به خوبی عمل کنند

اگر گراف دارای ساختارهای با پیچیدگی است و این کار به اطلاعات معنی و جهانی نیاز
دارد $node2vec$ ممکن است انتخاب بهتری باشد

اگر مسئله ما مسئله طبقه بندی است $node2vec$ بهتر عمل می کند

اگر گراف ساده است و فقط به اطلاعات معنی نیاز دارد $Deepwalk$ ممکن است برای
پایداری کافی و سازگاری باشد.





شکل:
(الف)



hash



$11 \rightarrow 3$

$111 \rightarrow 4$





$1334 \rightarrow 10$

$4433 \rightarrow 14$



هر دو گراف درخت های بازشده معادل دارند



computation Graph

برای هر دو طرف داریم
است

مرد ای رسیده ها ن در که می بیند یکبار

computation Graph

$\frac{v}{(e, s)}$

$$\text{mean}(V, f) = \frac{V}{f}$$

$$\text{mean}(\mu, \sigma) = \frac{v}{r}$$

$$h_{\text{cr}} = \frac{V}{\gamma} \quad \& \quad \frac{14}{\gamma} = \frac{V}{\gamma} = 10$$



$$h^0_{\mathcal{D}} = 4$$

$$h_{\text{sp}}^1 = \frac{1}{q} + \frac{1}{r} = \frac{1}{q}$$

برای هر دو گراف یکسان است

میرہا نفور کہ در قسمت اف سفین شد



مثال - باقی‌مانده در نقطه مشخص



مثال:

1 → 1 2 →
3 → 2

نمی‌توان بین رئوس ۲ کرافت‌ها را ایجاد کنیم و یک حالت پیرایه
که رأس‌های یک کرافت را به رئوس ۲ افزودیم به‌دور می‌توانیم آن‌ها را
حفظ کرد پس غیر یک‌ریخت هستند



برای تعیین یک ریختی کرافت را به چند مورد تقسیم کردیم:
تعداد رئوس: ۶

تعداد یال‌ها: ۸

درجه هر یک از رئوس:
همیشه یک یا دو

$K_1: 1$	$K_2: 2$	$N(1) = \{2, 3, 4\}$	$N(1) = \{2, 3, 4\}$
$K_2: 1$	$K_3: 2$	$N(2) = \{1, 3, 4\}$	$N(2) = \{1, 3, 4\}$
$K_3: 3$	$K_4: 3$	$N(3) = \{1, 2, 4\}$	$N(3) = \{1, 2, 4\}$
$K_4: 3$	$K_5: 4$	$N(4) = \{1, 2, 3\}$	$N(4) = \{1, 2, 3\}$
$K_5: 2$	$K_6: 2$	$N(5) = \{1, 2, 3, 4\}$	$N(5) = \{1, 2, 3, 4\}$
$K_6: 2$		$N(6) = \{1, 2, 3, 4\}$	$N(6) = \{1, 2, 3, 4\}$

$K=3$ g_1 g_2 g_3 g_4

شماره کرافت‌ها:


g_1



g_2



g_3



g_4

.


$$f_{G_1} = (r, r, r, 0)^T$$


$r = r$

h_1 :



h_2 :





$h_4: \dots$

$$f_H = (0, 1, 0, 1, 0)^T$$

برای راه های تشخیص غیر یقیناً بودن دو گراف استفاده از Graphlet ها است مادر شباهت
 Graphlet ها به اندازه ۳ به ای هر دو گراف در نظر گرفتیم همان طور که مشاهده می شود
 $f_{G1} \neq f_H$ است پس دو گراف یقیناً نیستند

سوال امتیازی:

Graphlet: Expressivity و WL روش های مبتنی بر گراف بسیار ساده هستند، این معنی می تواند
 اطلاعات دقیقی در مورد ساختار گراف بگیرد به عنوان مثال WL می تواند بین زیر گراف های هم شکل
 تمایز قائل شود در حالی که GCN ها نمی توانند از طرف دیگر GCN ها نسبت به Graphlet و WL بیان کمتری
 دارند اما مقیاس بزرگ تر هستند و می توانند گراف های بزرگتری مدیریت کنند
 استفاده در آشفتگی های گراف: Graphlet و WL برای آشفتگی های گراف مانند حذف کردن یا
 اضافه کردن راس ها و یال ها بسیار قوی هستند یعنی representation های آموخته شده از گراف باید آید از همدستی
 زمانی که گراف کمی تغییر می کند در مقابل GCN ها به افتخارات گراف حساس ترند و تغییرات کوچک
 در گراف می تواند تأثیر زیادی بر representation های آموخته شده داشته باشد
 برای داده GCN ها معمولاً نسبت به Graphlet و WL از نظر داده کارآمدتر هستند یعنی می توانند
 representation های خوش را با داده های کمتری یاد بگیرند چرا که GCN ها می توانند ساختار گراف
 و ویژگی راس را به طور همزمان یاد بگیرند در حالی که Graphlet و WL تنها به ساختار گراف متکی هستند
 با این حال نقاط قوت GCN ها می توانند یک ضعف باشند زیرا ممکن است در یادگیری از ساختارهای گراف
 نهایی بدون ویژگی های گره مؤثر نباشند.

لایه های محاسباتی: GCN می تواند از نظر محاسباتی هزینه زیادی داشته باشد به خصوص برای گراف های
 بزرگ زیرا شامل عملیات ماتریسی می شود WL به طور کلی سریع تر از GCN است اما به دلیل
 گراف های متعدد به چسبندگی و به چسبندگی مجدد هنوز

مقداری در برابر مقایسه با آنی دارد از طرف دیگر Graphlet از نظر مقایسه با آنی کارآمد است و می تواند برای
گراف های بزرگ استفاده شود.

انزیمات داده GC به مقادیر زیادی از داده های آماری بر حسب نداری شده برای عملکرد بهینه
نیاز دارد که می تواند برای برخی برنامه ها چالش برانگیز باشد. WL به مقداری داده بر حسب دار برای
مرحله بر حسب نداری اولیه نیاز دارد اما این می تواند کمتر از آنچه GC لازم دارد باشد.

Graphlet به داده های بر حسب نداری شده نیازی ندارد بنابراین برای کارهای یادگیری بدون
نظارت مناسب تر است.

GC برای ساختارهای گراف پیچیده با مقادیر زیادی از داده های بر حسب نداری شده مناسب تر
است. WL برای گراف های کوچکتر یا آنهایی که ساختارهای تکراری دارند و Graphlet برای
کارهای یادگیری بدون نظارت و گراف های بزرگ با ساختارهای مناسب تر است.